

0 Abstract

단락 0-1

A promising approach for improving reasoning in large language models is to use process reward models (PRMs). PRMs provide feedback at each step of a multi-step reasoning trace, improving credit assignment over outcome reward models (ORMs) that only provide feedback at the final step. However, collecting dense, per-step human labels is not scalable, and training PRMs from automatically-labeled data has thus far led to limited gains. With the goal of using PRMs to improve a base policy via test-time search and reinforcement learning (RL), we ask: “How should we design process rewards?” Our key insight is that, to be effective, the process reward for a step should measure progress: a change in the likelihood of producing a correct response in the future, before and after taking the step, as measured under a prover policy distinct from the base policy. Such progress values can distinguish good and bad steps generated by the base policy, even though the base policy itself cannot. Theoretically, we show that even weaker provers can improve the base policy, as long as they distinguish steps without being too misaligned with the base policy. Our results show that process rewards defined as progress under such provers improve the efficiency of exploration during test-time search and online RL. We empirically validate our claims by training process advantage verifiers (PAVs) to measure progress under such provers and show that compared to ORM, they are > 8% more accurate, and 1.5 — 5*x* more compute-efficient. Equipped with these insights, our PAVs enable one of the first results showing a 6x gain in sample efficiency for a policy trained using online RL with PRMs vs. ORMs.

문장 0-1-1

A promising approach for improving reasoning in large language models is to use process reward models (PRMs).

단위 해석

거대 언어 모델(LLM)의 추론 능력을 향상시키기 위한 유망한 접근 방식은 과정 보상 모델(PRMs, Process Reward Models)을 사용하는 것입니다.

보조 설명

- **[Process Reward Models (PRMs)]**: 최종 결과만 채점하는 것이 아니라, 추론 과정의 각 단계(Step)마다 피드백을 주는 모델입니다. 수학 문제처럼 여러 단계의 논리가 필요한 작업에서 중요합니다.

문장 0-1-2

PRMs provide feedback at each step of a multi-step reasoning trace, improving credit assignment over outcome reward models (ORMs) that only provide feedback at the final step.

단위 해석

PRM은 다단계 추론 과정의 각 단계마다 피드백을 제공하여, 마지막 단계에서만 피드백을 제공하는 결과 보상 모델(ORMs)보다 기여도 할당(credit assignment) 문제를 개선합니다.

보조 설명

- **[Credit Assignment]**: 결과가 틀렸을 때, 중간에 어떤 단계가 원인인지 파악하는 문제입니다. ORM은 이를 알기 어렵지만, PRM은 정확히 지적할 수 있습니다.

문장 0-1-3

However, collecting dense, per-step human labels is not scalable, and training PRMs from automatically-labeled data has thus far led to limited gains.

단위 해석

하지만 촘촘한(dense) 단계별 라벨을 사람이 직접 수집하는 것은 확장성이 떨어지며, 자동 라벨링된 데이터로 PRM을 학습시키는 방식은 지금까지 제한적인 성능 향상만을 보여주었습니다.

문장 0-1-4

With the goal of using PRMs to improve a base policy via test-time search and reinforcement learning (RL), we ask: “How should we design process rewards?”

단위 해석

테스트 타임 탐색(test-time search)과 강화학습(RL)을 통해 기본 정책(base policy)을 개선하기 위해 PRM을 사용한다는 목표 아래, 우리는 다음과 같은 질문을 던집니다: “과정 보상(process rewards)을 어떻게 설계해야 하는가?”

문장 0-1-5

Our key insight is that, to be effective, the process reward for a step should measure progress: a change in the likelihood of producing a correct response in the future, before and after taking the step, as measured under a prover policy distinct from the base policy.

단위 해석

우리의 핵심 통찰은, 과정 보상이 효과적이기 위해서는 '진척도(progress)'를 측정해야 한다는 것입니다. 여기서 진척도란, 기본 정책(base policy)과는 구별되는 별도의 '증명 정책(prover policy)' 하에서 측정했을 때, 해당 단계를 밟기 전과 후의 정답 도출 확률 변화량을 의미합니다.

- 보조 설명
- [Prover Policy]: 보상을 계산하기 위해 사용하는 별도의 평가 모델(정책)입니다. 저자들은 학습 대상인 Base Policy와 다른 모델을 써야 한다고 주장합니다.
 - [Progress]: 특정 단계를 수행함으로써 정답 확률이 얼마나 높아졌는지를 수치화한 것입니다.

문장 0-1-6

Such progress values can distinguish good and bad steps generated by the base policy, even though the base policy itself cannot.

단위 해석

이러한 진척도 값은 기본 정책 자체가 스스로 판단하지 못하는 경우에도, 기본 정책이 생성한 단계들 중 좋은 단계와 나쁜 단계를 구별해 낼 수 있습니다.

문장 0-1-7

Theoretically, we show that even weaker provers can improve the base policy, as long as they distinguish steps without being too misaligned with the base policy.

단위 해석

이론적으로, 우리는 더 약한 성능을 가진 증명자(prover)라도 기본 정책과 너무 어긋나지(misaligned) 않으면서 단계들을 구별할 수만 있다면, 기본 정책을 개선할 수 있음을 보였습니다.

문장 0-1-8

Our results show that process rewards defined as progress under such provers improve the efficiency of exploration during test-time search and online RL.

단위 해석

우리의 결과는 그러한 증명자 하에서 진척도로 정의된 과정 보상이 테스트 타임 탐색 및 온라인 RL 수행 시 탐색(exploration)의 효율성을 향상시킨다는 것을 보여줍니다.

문장 0-1-9

We empirically validate our claims by training process advantage verifiers (PAVs) to measure progress under such provers and show that compared to ORM, they are > 8% more accurate, and $1.5 - 5x$ more compute-efficient.

단위 해석

우리는 그러한 증명자 하에서 진척도를 측정하도록 '과정 어드밴티지 검증기(PAV, Process Advantage Verifiers)'를 학습시켜 주장을 경험적으로 검증하였으며, ORM과 비교했을 때 정확도는 8% 이상 높고, 연산 효율성은 1.5배에서 5배 더 높음을 보였습니다.

- 보조 설명
- [PAV (Process Advantage Verifier)]: 이 논문에서 제안하는 핵심 모델로, 특정 단계가 최종 성공 확률을 얼마나 높이는지(Advantage)를 예측합니다.

문장 0-1-10

Equipped with these insights, our PAVs enable one of the first results showing a 6x gain in sample efficiency for a policy trained using online RL with PRMs vs. ORMs.

단위 해석

이러한 통찰을 바탕으로, 우리의 PAV는 PRM을 사용한 온라인 RL이 ORM을 사용한 경우보다 샘플 효율성(sample efficiency)에서 6배의 이득을 얻는 최초의 결과 중 하나를 달성했습니다.

1 Introduction

단락 1-1

Trained reward models or verifiers are often used to improve math reasoning in large language models, either by re-ranking solutions at test-time (Collins, 2000) or during reinforcement learning (RL) (Uesato et al., 2022). Typically, verifiers are trained to predict the outcome of an entire reasoning trace, often referred to as outcome reward models (ORM) (Cobbe et al., 2021b; Hosseini et al., 2024). However, ORMs only provide a sparse signal of correctness, which is hard to learn from and inefficient to search against.

✅ 문장 1-1-1

Trained reward models or verifiers are often used to improve math reasoning in large language models, either by re-ranking solutions at test-time (Collins, 2000) or during reinforcement learning (RL) (Uesato et al., 2022).

🔍 단위 해석

학습된 보상 모델이나 검증기(verifier)는 테스트 타임에 솔루션을 재순위화(re-ranking)하거나 강화학습(RL) 과정에 활용됨으로써 거대 언어 모델의 수학적 추론 능력을 향상시키는 데 자주 사용됩니다.

✅ 문장 1-1-2

Typically, verifiers are trained to predict the outcome of an entire reasoning trace, often referred to as outcome reward models (ORM) (Cobbe et al., 2021b; Hosseini et al., 2024).

🔍 단위 해석

일반적으로 검증기는 전체 추론 과정의 최종 결과를 예측하도록 학습되며, 이를 흔히 결과 보상 모델(ORM)이라고 부릅니다.

✅ 문장 1-1-3

However, ORMs only provide a sparse signal of correctness, which is hard to learn from and inefficient to search against.

🔍 단위 해석

그러나 ORM은 정답 여부에 대한 희소한(sparse) 신호만을 제공하기 때문에, 모델이 이를 통해 학습하기 어렵고 탐색(search) 효율성도 떨어집니다.

💡 보조 설명

- **[Sparse Signal]:** 추론 과정이 길어도 마지막에 “맞음/틀림” 딱 한 번만 신호를 주기 때문에, 중간에 무엇을 잘하고 못했는지 알기 어렵다는 의미입니다.

📖 단락 1-2

This challenge is alleviated by fine-grained supervision, in theory. For reasoning, prior works train process reward models (PRMs) that assign intermediate rewards after each step of search (Snell et al., 2024) or during RL. While Lightman et al. (2023) obtains PRM annotations from human raters, this approach is not scalable. More recent works (Wang et al., 2024; Luo et al., 2024) train PRMs to predict automatically-generated annotations that estimate future success of solving the problem, akin to value functions in RL. So far, automated PRMs, especially as dense rewards in RL, only improve by 1-2% over ORMs (Shao et al., 2024), raising doubts about their utility.

✅ 문장 1-2-1

This challenge is alleviated by fine-grained supervision, in theory.

🔍 단위 해석

이러한 문제는 이론적으로 세밀한(fine-grained) 지도 학습을 통해 완화될 수 있습니다.

✅ 문장 1-2-2

For reasoning, prior works train process reward models (PRMs) that assign intermediate rewards after each step of search (Snell et al., 2024) or during RL.

🔍 단위 해석

추론 작업을 위해, 선행 연구들은 탐색의 각 단계 후 또는 RL 과정 중에 중간 보상을 할당하는 과정 보상 모델(PRM)을 학습시켰습니다.

✅ 문장 1-2-3

While Lightman et al. (2023) obtains PRM annotations from human raters, this approach is not scalable.

🔍 단위 해석

Lightman 등(2023)은 인간 평가자로부터 PRM 주식(라벨)을 얻었지만, 이 방식은 확장성(scalable)이 부족합니다.

✅ 문장 1-2-4

More recent works (Wang et al., 2024; Luo et al., 2024) train PRMs to predict automatically-generated annotations that estimate future success of solving the problem, akin to value functions in RL.

🔍 단위 해석

더 최근의 연구들은 RL의 가치 함수(value functions)와 유사하게, 문제 해결의 미래 성공 가능성을 추정하는 자동 생성된 주석을 예측하도록 PRM을 학습시킵니다.

✔ 문장 1-2-5

So far, automated PRMs, especially as dense rewards in RL, only improve by 1-2% over ORMs (Shao et al., 2024), raising doubts about their utility.

🔍 단위 해석

지금까지 자동화된 PRM은, 특히 RL에서 밀집 보상(dense rewards)으로 사용될 때 ORM 대비 성능 향상이 1-2%에 불과하여 그 효용성에 의문이 제기되고 있습니다.

📖 단락 1-3

To resolve these uncertainties, in this paper, our goal is to train automated PRMs that can improve a base policy, via compute efficient test-time search, and sample-efficient online RL with PRMs as dense rewards. For this, we first ask: (i) what should the per-step process rewards measure, and (ii) what kind of automated data collection strategy should we use to train PRMs that predict this measure.

✔ 문장 1-3-1

To resolve these uncertainties, in this paper, our goal is to train automated PRMs that can improve a base policy, via compute efficient test-time search, and sample-efficient online RL with PRMs as dense rewards.

🔍 단위 해석

이러한 불확실성을 해소하기 위해, 본 논문의 목표는 연산 효율적인 테스트 타임 탐색과 PRM을 밀집 보상으로 사용하는 샘플 효율적인 온라인 RL을 통해 기본 정책을 개선할 수 있는 자동화된 PRM을 학습시키는 것입니다.

✔ 문장 1-3-2

For this, we first ask: (i) what should the per-step process rewards measure, and (ii) what kind of automated data collection strategy should we use to train PRMs that predict this measure.

🔍 단위 해석

이를 위해 우리는 먼저 다음을 질문합니다: (i) 단계별 과정 보상은 무엇을 측정해야 하는가? (ii) 이 측정값을 예측하는 PRM을 학습시키기 위해 어떤 자동화된 데이터 수집 전략을 사용해야 하는가?

📖 단락 1-4

For (i), conventional belief (Lightman et al., 2023; Uesato et al., 2022) has been to measure mathematical correctness or relevance of steps. But, it is unclear if this supervision yields the most improvement in the base policy (e.g., a policy may need to generate simpler, repetitive, and even incorrect steps to explore and discover the final answer during test-time search and RL). Our key insight is that per-step, process rewards that measure notion of progress: change in the likelihood of arriving at a correct final answer before and after taking the step, are effective, for both test-time beam search and online RL. Reinforcing promising steps that make progress regardless of whether they appear in a correct or incorrect trace results in overall better exploration of possible answers at initial steps, which is crucial when the approach to solve a problem is not clear. Formally, such rewards correspond to per-step advantages of steps from the RL literature (Sutton & Barto, 2018). We empirically show that using advantages in conjunction with ORM rewards outperforms using future probabilities of success or Q-values (Wang et al., 2024) for both search and RL. This is because, in the combinatorial space of responses, Q-values mainly “exploit” states whereas advantages also “explore” steps that make the most progress towards the final answer.

✔ 문장 1-4-1

For (i), conventional belief (Lightman et al., 2023; Uesato et al., 2022) has been to measure mathematical correctness or relevance of steps.

🔍 단위 해석

첫 번째 질문에 대해, 기존의 통념은 각 단계의 수학적 정확성(correctness)이나 관련성(relevance)을 측정해야 한다는 것이었습니다.

✔ 문장 1-4-2

But, it is unclear if this supervision yields the most improvement in the base policy (e.g., a policy may need to generate simpler, repetitive, and even incorrect steps to explore and discover the final answer during test-time search and RL).

🔍 단위 해석

하지만 이러한 지도 방식이 기본 정책에 가장 큰 개선을 가져오는지는 불분명합니다(예를 들어, 정책은 테스트 타임 탐색이나 RL 도중 최종 정답을 찾기 위해 더 단순하거나, 반복적이거나, 심지어 틀린 단계들을 생성하여 탐색해 볼 필요가 있을 수 있기 때문입니다).

💡 보조 설명

- **[Counter-intuitive Insight]:** 엄밀히 수학적으로 틀린 단계라도, 정답을 찾기 위한 탐색 과정에서는 유용한 '징검다리'가 될 수 있다는 저자들의 통찰입니다.

✔ 문장 1-4-3

Our key insight is that per-step, process rewards that measure notion of progress: change in the likelihood of arriving at a correct final answer before and after taking the step, are effective, for both test-time beam search and online RL.

🔍 단위 해석

우리의 핵심 통찰은, '진척도(progress)'의 개념, 즉 해당 단계를 수행하기 전과 후의 정답 도달 확률의 변화량을 측정하는 단계별 과정 보상이 테스트 타임 빔 서치 (beam search)와 온라인 RL 모두에 효과적이라는 것입니다.

✔ 문장 1-4-4

Reinforcing promising steps that make progress regardless of whether they appear in a correct or incorrect trace results in overall better exploration of possible answers at initial steps, which is crucial when the approach to solve a problem is not clear.

🔍 단위 해석

해당 단계가 정답 경로에 포함되었든 오답 경로에 포함되었든 관계없이, 진척도를 만드는 유망한 단계들을 강화(reinforcing)하면 초기 단계에서 가능한 답변들에 대한 전반적인 탐색 능력이 향상되며, 이는 문제 해결 방법이 명확하지 않을 때 매우 중요합니다.

✔ 문장 1-4-5

Formally, such rewards correspond to per-step advantages of steps from the RL literature (Sutton & Barto, 2018).

🔍 단위 해석

수식적으로, 이러한 보상은 강화학습 문헌에서 말하는 단계별 어드밴티지(advantages)에 해당합니다.

💡 보조 설명

- **[Advantage]:** $A(s, a) = Q(s, a) - V(s)$. 특정 상태 s 에서 행동 a 를 취했을 때, 평균적인 기대치(V)보다 얼마나 더 좋은지(Q)를 나타내는 값입니다.

✔ 문장 1-4-6

We empirically show that using advantages in conjunction with ORM rewards outperforms using future probabilities of success or Q-values (Wang et al., 2024) for both search and RL.

🔍 단위 해석

우리는 어드밴티지를 ORM 보상과 함께 사용하는 것이, 미래 성공 확률이나 Q-값만을 사용하는 것보다 탐색과 RL 모두에서 성능이 우수함을 경험적으로 보입니다.

✔ 문장 1-4-7

This is because, in the combinatorial space of responses, Q-values mainly “exploit” states whereas advantages also “explore” steps that make the most progress towards the final answer.

🔍 단위 해석

이는 조합 가능한 응답 공간에서 Q-값은 주로 현재 상태를 '이용(exploit)'하는 데 치중하는 반면, 어드밴티지는 정답을 향해 가장 큰 진척을 보이는 단계를 '탐색(explore)'하는 기능도 수행하기 때문입니다.

🖼️ 시각 자료 [Figure 1]

(원문 캡션: **Figure 1:** Process advantage verifier (PAV): Process reward for a step is defined as progress (advantage) under the prover policy, i.e., change in prover policy’s success rate before and after the step. (a): The base policy samples both correct and incorrect steps but struggles to succeed from either. A strong prover completes the solution from any step, making no progress on either 1 or 2 (both scored 0.0). Conversely, a complementary prover policy distinguishes 1, 2 more prominently (only succeeds from 1). (b,c): Compared to ORMs, PAVs are 5x more compute efficient, 10% more accurate in test-time search, and 6x more sample efficient for RL.)

🔍 캡션 해석

그림 1: 과정 어드밴티지 검증기(PAV): 단계별 과정 보상은 증명 정책(prover policy) 하에서의 진척도(어드밴티지), 즉 단계를 밟기 전후의 증명 정책 성공률 변화로 정의됩니다.

(a): 기본 정책은 정답 단계와 오답 단계를 모두 생성하지만, 그 이후 성공하는 데 어려움을 겪습니다. 너무 강력한 증명자는 어떤 단계에서든 문제를 해결해 버리기 때문에, 정답 단계(1)나 오답 단계(2) 모두에서 진척도를 0.0으로 평가하여 변별력이 없습니다. 반면, 상호보완적(complementary) 증명 정책은 1번과 2번을 더 명확히 구별합니다(1번에서만 성공).

(b, c): ORM과 비교할 때, PAV는 테스트 타임 탐색에서 5배 더 연산 효율적이고 10% 더 정확하며, RL에서는 6배 더 샘플 효율적입니다.

📄 PDF 시각 분석

- 구조 **(a):** 트리 구조를 통해 *****강력한 증명자(Very capable prover)*****와 *****상호보완적 증명자(Good prover)*****의 차이를 시각화했습니다.
 - **강력한 증명자:** 이미 너무 똑똑해서 힌트(중간 단계)가 있든 없든 정답을 맞힙니다. 따라서 중간 단계의 가치를 0(진척 없음)으로 평가하는 역설적인 상황이 발생합니다.
 - **상호보완적 증명자:** 적절한 힌트(올바른 중간 단계)가 주어졌을 때만 정답 확률이 올라갑니다. 따라서 좋은 단계에 높은 점수(1.0)를 줍니다.
- 데이터 **(b): Search Efficiency.** X축(샘플 수)이 증가할수록 정확도가 오르는데, PAV(주황색)가 ORM(파란색)보다 훨씬 적은 샘플 수(2^3 vs 2^6)로 동일한 정확도에 도달함을 보여줍니다(화살표로 5배 효율성 강조).

- 데이터 ©: **RL Efficiency**. 학습 반복(Iteration)에 따른 정확도 그래프에서 PAV-RL이 ORM-RL보다 훨씬 가파르게 성능이 향상됨을 보여줍니다(6배 효율성).