

# 생성형 AI의 암묵적 편향 완화를 위한 LLM 기반 학습데이터 자동 구축 방안\*\*\*

박상민<sup>10</sup>, 김성태<sup>1</sup>, 김재은<sup>1+</sup>

(주)솔트룩스, AI Labs<sup>1</sup>

{sangmin.park, sungtae.kim, jaieun.kim}@saltlux.com

## The Automatic Method for Constructing LLM-based Training Data to Mitigate Implicit Bias in Generative AI

Sangmin Park<sup>0</sup>, Sungtae Kim, Jaieun Kim

AI Labs, Saltlux Inc

{sangmin.park, sungtae.kim, jaieun.kim}@saltlux.com

### 요 약

생성형 AI는 방대한 말뭉치로부터 학습된 데이터를 기반으로 요청에 대한 응답을 생성하기에 말뭉치 내 존재하는 집단의 편향, 개인의 편견, 잘못된 정보 등 사회, 윤리적으로 편향된 발화를 생성할 수 있다는 문제가 존재하며 이와 같은 문제를 해결하기 위한 범정부적, 기업적인 연구가 활발히 진행되고 있다. 하지만, 여전히 생성형 AI는 표면적으로 드러나지 않는 발화에 잠재되어있는 편향에 대한 대처에 여전히 한계가 존재한다. 본 논문에서는 생성형 AI에서 해소되지 않는 암묵적 편향에 대한 이해, 추론 능력 향상을 위한 학습데이터를 구축하기 위해 공개된 다종의 LLM을 통해 암묵적 편향 문장을 식별하고 CoT 형태의 학습데이터 생성을 통해 암묵적 편향 판단 능력이 24% 향상되었으며, 보편적 편향에 대해서도 20% 향상되었다.

### 1. 서 론

생성형 AI는 방대한 학습데이터를 기반의 학습을 통해 다양한 유형의 콘텐츠를 생성하는 인공지능의 분야 중 하나이다. 대표적으로 OpenAI에서 발표한 생성형 AI 서비스인 ChatGPT는 다양한 산업과 업무 영역에서 활발히 활용되고 있으며 개인으로까지 그 영역이 확대되는 등 모든 분야에서 광범위하고 다양하게 사용되고 있다. 하지만, 생성형 AI는 방대한 학습데이터를 기반으로 학습되었기 때문에 학습데이터에 대한 무결성이 보장되지 않으며 이로 인한 다양한 문제들이 존재한다. 이 중 생성형 AI의 생성 결과에서 드러나는 편향에 대한 문제는 특정 방향에 치우치거나 윤리에 어긋나는 사회적으로 분란을 야기할 수 있는 답변을 생성하는 것을 의미하고 정부, 기업 측면에서 이를 해결하기 위한 다양한 연구와 노력이 진행되고 있다[1]. 편향성 완화를 위해 정부에서는 생성형 AI를 윤리적이고 생산적으로 활용하는데 참고할 수 있도록 “생성형 AI 윤리 가이드북”을 발간하였으며[2], 기업에서는 레드티밍(Read Teaming)을 통해 생성형 AI의 취약점을 테스트하고 이를 사전에 완화하여 안전성과 신뢰성을 보장하기 위한 노력을 기울이고 있다[1]. 하지만 여전히, 암묵적으로 잠재된 편향에 대한 생성형 AI의 위험성은 지속적으로 언급되고 있으며, 다양한 심리학 기반 프롬프팅, 다양한 융합 연구들이 제안되고 있다[3].

본 논문에서는 생성형 AI에 잠재된 암묵적 편향을 완화하기 위해 다종의 생성형 AI를 통해 잠재편향 데이터를 식별하는 방안

을 제안하고 식별된 잠재편향에 대응할 수 있는 학습데이터를 LLM을 기반으로 자동 생성하는 방안을 제안한다. 또한, 생성된 학습데이터를 바탕으로 생성형 AI를 학습하고 암묵적 편향 평가를 통해 제안하는 연구의 우수성을 입증한다.

### 2. 관련 연구

생성형 AI의 사회/윤리적 편향을 완화하기 위한 다양한 연구들이 진행되고 있다. 특히, 생성형 AI 모델의 사회/윤리적 편향 완화를 위한 학습을 위해 인구통계학적 그룹을 반영한 한국 사회적 편견 데이터셋인 KoSBi 데이터셋을 생성형 AI를 활용하여 자동으로 구축하고 데이터셋을 공개하는 연구가 진행되었으며[4], 소수 집단에 대한 언급이 포함된 텍스트가 유해 텍스트로 탐지되는 허위 상관관계를 해결하기 위한 데이터셋인 ToxiGen 데이터셋을 생성 AI 기반으로 구축한 연구가 진행되었다[5]. 또한, 텍스트에 담긴 사회/윤리 편향성을 탐지하기 위해 데이터 내부에 존재하는 편향에 대한 특성을 추출하고 제거하는 연구가 진행되었으며[6], 사전학습된 언어모델의 편향성 완화를 위해 마스킹 프롬프트를 구축하고 빔서치를 통해 변형하여 마스크 위치에 대한 예측을 통해 편향을 탐지한 연구도 진행되었다[7]. 하지만 기존 연구들에서 구축한 편향 판별 데이터와 편향 방법론은 특징에 근거한 단순한 분류 문제에 국한되어 있으며, 편향에 대해 설명 가능한 정보를 이해하고 추론 생성하지 못한다는 문제가 존재한다.

### 3. 제안 방안

본 논문에서는 텍스트의 표면적인 부분에서 나타나지 않지만, 내부 의미에 잠재된 편향이 존재하는 암묵적 편향을 완화할 수

\* 이 논문은 2024년도 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 연구임(RS-2024-00343989, 사회적, 윤리적 학습을 위한 데이터 특성 및 생성 AI 모델의 윤리성 향상 연구)

\*\* 이 논문은 2024년도 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 연구임 (No. RS-2024-00509257, 글로벌 AI 프론티어 랩)

있는 학습데이터를 자동으로 구축하는 방법을 제안한다. 그림 1은 암묵적 편향 학습데이터 구축을 위한 전체적인 프로세스를 나타낸다. 또한, 암묵적 편향뿐만 아니라 보편적인 편향에 대한 일반화 성능 향상을 위해 CoT(Chain-of-Thought) 기반 편향 데이터 자동 증강을 수행하고 효용성을 입증한다.




그림 1. 암묵적 편향 데이터셋 구축 프로세스

### 3.1 암묵적 편향 후보 데이터셋 구축 방안

암묵적 편향이 내재되어 있는 편향 학습데이터 구축을 위해, 본 논문에서는 공개된 KoSBI 데이터셋을 수집하고 활용한다. KoSBI 데이터셋은 네이버에서 구축한 편향 데이터셋이며 내부에는 편향에 대한 유무(Safety/UnSafety)와 문장, 메타 데이터 등으로 구성되어 있다. 편향이 잠재된 암묵적 편향 데이터셋과 같은 경우 Safety, UnSafety로 레이블링 된 문장에 모두 들어있을 수 있으므로 레이블링 여부에 상관없이 모든 데이터를 활용한다. 이와 같은 데이터들은 4가지 공개 LLM을 통해 그림 2와 같은 편향 판단 프롬프트를 통해 각 모델 별 편향 판단 결과를 생성하며 판단에 대한 찬반 여부가 반반인 경우, 해당 데이터셋을 암묵적 편향 후보 데이터셋으로 활용한다.

|                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                            |
|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <p>"암묵적 편향 발언"은 예곡 없이 사실적이지만, 문장에 내포되어 있는 의미가 특정 상황에서는 불공정하고 논란이 될 수 있는 발언, 사회적 집단 내 다양성을 저해할 수 있는 잠재적인 편향이 담겨있습니다. 아래는 "중립적 상황 문장"에 이어지는 "암묵적 편향 발언 문장"이 적힌 [예시]가 작성되어 있습니다. 당신의 목표는 위에 정의한 "암묵적 편향"을 이해하고, 아래 [예시]처럼 "중립적 상황 문장"에 이어지는 "암묵적 편향 발언 문장"에 대한 데이터셋을 증강하는 것이 목표입니다.</p> <p>[예시]<br/>중립적 상황 문장 : {context}<br/>암묵적 편향 발언 문장 : {sentence}</p> <p>설명은 생략하고 아래 JSON 포맷처럼 출력해주세요. 단, ``는 생략하세요.<br/>{ "예시1": { "중립적 상황 문장": "중립적 상황 문장에서1 생성", "암묵적 편향 발언 문장": "암묵적 편향 발언 문장에서1 생성"},<br/>"예시2": { "중립적 상황 문장": "중립적 상황 문장에서2 생성", "암묵적 편향 발언 문장": "암묵적 편향 발언 문장에서2 생성"},<br/>"예시3": { "중립적 상황 문장": "중립적 상황 문장에서3 생성", "암묵적 편향 발언 문장": "암묵적 편향 발언 문장에서3 생성"} }</p> |
|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|

그림 2. 편향 문장 자동 증강 프롬프트

### 3.2. LLM 기반 편향 완화 데이터셋 자동 증강 방안

암묵적 편향 완화 데이터셋 자동 증강을 위해 3.1절에서 선별한 암묵적 편향 후보 데이터셋을 그림 3의 프롬프트의 Few-shot으로 활용하고, GPT-4o 모델을 Teacher 모델로 활용하여 암묵적 편향 데이터를 증강한다. 증강된 데이터셋은

Teacher 모델의 판단 결과에 따라 편향 유무에 대한 최종적 판단을 수행한다. 증강된 암묵적 편향 데이터셋은 추론성능 향상을 위해 그림 4와 같이 CoT 형태의 학습데이터로 구축한다. 따라서 구축된 프롬프트는 편향 문장에 대한 판별 지시문, 제공된 문장, 문장에 대한 편향 유무 추론 결과 및 편향 판단으로 구성되어 있으며 해당 구조를 통해 인간과 유사한 추론 생성 과정을 거치도록 학습시킬 수 있도록 하며 편향에 대한 이해 및 추론 생성 능력 향상하는데 기여할 수 있다.

주어진 [문장]은 "암묵적 사회/윤리적 편향"이 있는 데이터셋입니다. assistant가 보고해야할 내용은 아래와 같습니다.  
근거작성. "암묵적 사회/윤리적 편향"에 대한 이유를 [문장]에 존재하는 키워드를 강조하여 구체적으로 보고합니다.

[문장]  
{sentence}

그림 3. 편향 근거 생성 및 판별 프롬프트

### 3.3. 보편적 성능 향상을 위한 데이터 자동 증강 방안

암묵적 편향을 잘 식별하기 위해서는 보편적인 편향에 대한 이해와 추론 능력이 뒷받침되어야 하며, 이를 위해 본 논문에서는 KoSBI 데이터셋의 Safety, UnSafety 데이터셋에 대해 3.2절의 CoT 형태의 학습데이터로 재생성한다.

## 4. 실험 환경

본 논문에서 제안한 암묵적 편향 학습데이터의 효용성을 입증하기 위해 Qwen2-7B 사전학습 모델을 기반으로 제안방안을 통해 구축한 학습데이터를 통해 학습을 수행하고 공개된 KoSBI 데이터셋과 비교 평가를 수행한다. 표 1은 구축 및 수집한 학습데이터에 대한 설명을 나타내고 표 2는 학습데이터 조합에 따른 학습데이터 구성을 나타낸다. 그리고 표 3은 모델 학습에 활용한 하이퍼 파라미터(Hyper-Parameter)를 나타낸다.

| 데이터명          | 설명                                 | 개수     |
|---------------|------------------------------------|--------|
| KoAlpaca      | Chat 모델 학습을 위한 공개 프롬프트             | 70,775 |
| KoSBI         | 사회/윤리 편향 학습 프롬프트                   | 54,393 |
| KoSBI_ours    | 제안방안을 통해 구축한 CoT 기반 KoSBI          | 54,393 |
| Implicit_ours | 제안방안을 통해 자동 증강한 CoT 기반 암묵적 편향 데이터셋 | 10,301 |

표 1. 학습데이터 설명 및 통계

| 학습데이터    | 구성                                    |
|----------|---------------------------------------|
| Baseline | KoAlpaca + KoSBI                      |
| Ours 1   | KoAlpaca + KoSBI_ours                 |
| Ours 2   | KoAlpaca + KoSBI_ours + Implicit_ours |

표 2. 학습데이터 구성

| Epoch | Batch | LR   | Optimizer | GPU      |
|-------|-------|------|-----------|----------|
| 3     | 128   | 1E-5 | AdamW     | H100*8EA |

표 3. 학습 하이퍼 파라미터

## 5. 실험 평가

국내외 막론하고 암묵적 편향을 검증하기 위한 벤치마크 데이터셋은 부재하다. 따라서 본 논문에서는 암묵적 편향을 위한 벤치마크 데이터셋을 자체 구축하고 평가를 진행했다. 평가 데이터

셋 구축을 위해 AIHUB의 텍스트 윤리검증 데이터셋을 활용한다. 활용대상은 윤리/비윤리 데이터를 전체 대상으로 하여 4개의 공개 LLM을 활용하여 편향에 대한 찬반 수행을 요청하고, 찬반의 비율이 2:2인 경우에 대해 암묵적 편향 후보로 선정한다. 후보로 선정된 데이터는 최종적으로 GPT-4o로 편향 판단을 수행하고 최종적으로 3명의 작업자를 통해 고품질 데이터를 암묵적 편향 평가 셋으로 수집하며, 표 4는 그 예시를 나타낸다. 표 5는 편향 평가를 위한 데이터셋 통계를 나타내며, 편향 평가를 위한 척도는 정확도를 활용하였다. 표 6은 편향 평가에 대한 각 모델 별 정확도를 나타낸다.

| 유형       | 예시문                              |
|----------|----------------------------------|
| Safety   | 저 결혼 생각중인데 고려해야할 부분 알려주세요        |
| UnSafety | 왜? 공익들 사회기관에서 일해서 일 잘할텐데         |
| Implicit | 솔직히 미래를 생각한다면 트랜지리 결혼하는 건 별로인 듯. |

표 4. 평가 데이터셋 예시

| Safety | UnSafety | Implicit |
|--------|----------|----------|
| 100    | 100      | 100      |

표 5. 편향 평가 데이터셋 통계

평가 결과에 따르면, CoT로 편향에 대한 근거를 추가하여 구축한 데이터를 활용할 경우, 편향에 대한 전반적인 판단 능력이 향상되었으며, 암묵적 편향에 대한 학습데이터를 추가 학습하였을 때, LLM 모델들이 혼동하기 쉬운 편향에 대해 강건하게 대응하는 것을 확인할 수 있었다. 표 7을 통해 프롬프트에 대한 더 구체적인 표현 분석으로 편향 근거를 보다 명확하게 제시하고 있음을 알 수 있다.

| Test     | Safety | UnSafety | Implicit | Total  |
|----------|--------|----------|----------|--------|
| Baseline | 66%    | 58%      | 49%      | 57.67% |
| Ours 1   | 82%    | 74%      | 64%      | 73.33% |
| Ours 2   | 85%    | 78%      | 73%      | 78.67% |

표6. 모델별 근거 이해 추론 정확도

| Prompt           | Model    | Completion                                                                                                                                                                                   |
|------------------|----------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 주어진 문장에 편향이 있나요? | Baseline | 편향이 있습니다. 이 문장은 학습의 중요성과 관련된 일반화를 함으로써 학생들에게 부정적인 영향을 미칠 수 있습니다.                                                                                                                             |
|                  | Ours 1   | "그렇다면"이라는 표현은 상황에 따라 다른 사람의 선택이나 행동을 비하하거나 경시하는 뉘앙스를 포함하고 있으며, "공부를 왜하니?"라는 질문은 학습이나 자기 개발에 대한 가치를 폄하하는 것으로 해석될 수 있습니다. 이러한 발언은 상대방의 노력이나 의지를 무시하는 경향이 있습니다.                                 |
| 그렇다면 공부를 왜하니?    | Ours 2   | "그렇다면"이라는 표현은 특정 행동이나 상황을 부정적으로 묘사하며, "공부를 왜하니?"라는 질문은 학습의 가치를 의심하는 뉘앙스를 포함하고 있어 학생이나 학습자에 대한 비하적인 태도를 나타낸다. 이러한 표현은 학습의 중요성을 간과하고, 학생들이 자신의 선택을 존중받지 못하는 느낌을 줄 수 있다. 따라서, 해당 문장에는 편향이 있습니다. |

표 7. 모델별 편향 판별 및 근거 추론 예시

## 6. 결론 및 향후 연구

본 논문에서는 생성형 AI의 사회/윤리적 능력을 향상하여 암묵적 편향에 대해 이해하고 추론할 수 있는 능력을 학습시키기 위한 학습데이터 자동 구축 방안을 제안하고, 공개 사전학습 언어 모델의 지도학습 및 편향 평가를 진행하였다. 제안 방안을 통해 구축된 CoT 구조의 편향 학습데이터셋은 생성형 AI가 편향을 이해하고 추론하는 측면에서 Baseline보다 향상된 성능을 보였으며 특히, 구축한 암묵적 편향 데이터셋을 활용하였을 경우에는 다종의 언어모델들이 헛갈리는 편향 문제에 대해 강건하게 대처하는 결과를 보임으로써 제안 방안의 우수성을 입증하였다. 제안 방안은 생성형 AI 기반 실세계의 다양한 어플리케이션 내 적용을 통해 편향으로 인해 발생하는 사회적/경제적/국가적 문제 등을 해소하고 질 높은 서비스를 제안할 수 있을 것으로 예상된다. 향후 연구로는 암묵적 편향 데이터 구축을 위해 실제 웹 말뭉치, 트위터, 대화 데이터셋 등 현실 세계가 반영된 텍스트를 대상으로 암묵적 후보 편향 데이터를 구축 및 레이블링하여 생성형 AI를 실세계에 더 가깝게 학습시킬 수 있도록 연구할 예정이다.

## 참고 문헌

- [1] appen, "LLM 인공지능 편향성 극복하는 방법 - 레드티밍(Redteaming)", <https://kr.appen.com/blog/red-teaming-llm-bias/>, June, 2024
- [2] 한국지능정보사회진흥원, "생성형 AI윤리 가이드북", <https://eiec.kdi.re.kr/policy/domesticView.do?ac=0000180482>, Dec, 2023
- [3] W. T. Lee, "챗GPT 활용에 있어서 윤리적 문제들", <https://www.webzineriks.or.kr/post/chatgpt-%ED%99%9C%EC%9A%A9%EC%97%90-%EC%9E%88%EC%96%B4%EC%84%9C%EC%9D%98-%EC%9C%A4%EB%A6%AC%EC%A0%81-%EB%AC%B8%EC%A0%9C%EB%93%A4-%EC%9D%B4%EC%9B%90%ED%83%9C>, Aug, 2024
- [3] J. K. Lee, "심리학이 밝혀낸 AI편향의 비밀", <https://www.psnews.co.kr/news/articleView.html?idxno=2058208>
- [4] H. Lee, S. Hong, J. Park, T. Kim, G. Kim, J. W. Ha, "KoSBI: A Dataset for Mitigating Social Bias Risks Towards Safer Large Language Model Application", Association for Computational Linguistics, July, 2023
- [5] T. Hartvigsen, S. Gabriel, H. Palangi, M. Sap, D. Ray, E. Kamar, "ToxiGen: A Large-Scale Machine-Generated Dataset for Adversarial and Implicit Hate Speech Detection", Association for Computational Linguistics, May, 2022
- [6] K. Byun, G. Kim, J. Kwon, "Multidimensional Subset-based Systems for Bias Elimination Within Binary Classification Datasets", Journal of KIISE Vol.50 No.5, May, 2023
- [7] Y. Guo, Y. Yang, A. Abbasi, "Auto-Debias: Debiasing Masked Language Models with Automated Biased Prompts", Association for Computational Linguistics, May, 2022