

한국어 생성문서의 사실성 평가에 대한 연구

김민호[○], 노지현, 배경만

한국전자통신연구원

{kimmh, jihyeon.roh, kyoungman.bae}@etri.re.kr

A Study on Factuality Evaluation for Korean Documents

Minho Kim[○], Jihyeon Roh, Kyoungman Bae

Electronics and Telecommunications Research Institute (ETRI)

요 약

한국어 생성 문서에 대해 사실성 평가를 할 수 있는 프레임워크를 제시한다. 환각을 통한 거짓 콘텐츠 생성의 가능성이 있는 수많은 언어모델들이 공개되고 있는 상황에서 그 중요성이 더해지고 있기 때문이다. 한국어 평가셋과 한국어 문서의 사실성 평가를 위한 소프트웨어를 제시하였다. 사실성 평가 대상과 비대상의 구분할 수 있는 모듈을 포함하여 코어 원소 사실 문장을 선별할 수 있도록 하였다. 실험을 통해 구축된 파이프라인의 효과성을 보였다.

1. 서 론

사실 검증, 즉, 팩트체크(fact-checking)은 주어진 주장(claims)이 사실인지 거짓인지를 판별하는 과정이다. 사실성 평가는 문서 전체의 사실성 정도를 측정하는 과정으로 볼 수 있다. 최근 생성형 언어모델은 환각(hallucination)이라는 현상을 통해 종종 거짓된 콘텐츠를 양산해 낸다. 특히, 생성형 언어모델의 폭발적인 증가에 힘입어 엄청난 양의 텍스트들이 생성되고 있다. 이러한 현실은 사실성 평가 기술의 중요성을 증대시켜 많은 연구자들의 관심이 되어 왔다[1]. 그 결과물로서, 영어의 경우 사실성 평가를 위한 다수의 프레임워크가 존재하지만, 한국어의 경우 거의 전무하다.

최근 영어 생성문서의 사실성 평가를 위한 프레임워크로서 FactScore가 제시되었다[2]. 비록 문서의 사실성 평가를 위한 개념은 제시되었지만, 한국어 생성문서에 적용할 수는 없는 상황이다. 왜냐하면, 평가용 데이터집합이 영어 문서이며, 원소 사실 추출 방법도 영어에서 가능한 방법을 제시하였기 때문이다. 또한, 사실 검증에 사용될 지식 DB도 영어 위키백과를 기반으로 개발되었다.

본 논문에서는 이러한 제한 사항을 해결하여 한국어 생성 문서의 사실성 평가할 수 있는 프레임워크를 제시한다. 기본 개념은 영어 문서를 위한 FactScore를 따랐으나, 세부 내용은 한국어에 적합하게 새롭게 개발되었다.

정확한 평가를 위해서는 사실성 검증 평가 대상을 구분하여 필터링 하는 과정이 필요하다. 왜냐하면, 많은 언어모델들이 텍스트 생성 요청을 받았을 때, 요청 받은 목적 이외의 비사실적 문장들을 종종 생성하기 때문이다. 이런 문장들은 사실성 평가를 방해하는 치명적인 요소인데 반해 그 중요성이 간과되었다. 본 논문에서는 이러한 문제를 해결하기 위해 사실성 검증 비대상을 필터링하기 위한 모듈도 제시하였다. 실험을 통해 언어모델 기반의 구현 가능성을 제시하였다. 개발된 프레임워크는 온라인으로 공개하였다(<https://github.com/ETRI-XAINLP/KorFactScore>).

2. 시스템 구성

사실성 평가 시스템은 그림 1에 주어진 바와 같다. 생성문서가 입력되면 문장 단위로 분할이 이루어진다. 각 문장에 대해 사실성 검증 평가 대상 여부를




그림 1. 한국어 사실성 평가 시스템

판단한다. 사실성 검증 비대상 문장의 타입은 매우 다양하다. 예를 들어, 해당 주제에 대한 정보를 알 수 없어 추가 정보 검색을 제안하는 경우, 추가적인 정보를 요청하는 경우, 생성을 기권한 경우, 정확한 정보를 확신할 수 없어 주제와 연관된 특성에 대한 정형적인 (stereotype) 답변을 한 경우, 추측성 내용을 생성한 경우, 안전 등의 문제로 답변을 거절한(refuse) 경우 등이 해당될 수 있다. 아래 표에서 그 대표적인 예시를 제공한다. 이러한 문장들은 필터링되어 평가 대상에서 제외된다.

- “2023년 시점의 정보를 기반으로 한 자세한 내용은 현재 제공된 자료에 포함되어 있지 않으므로, 최신 상황에 대해서는 최근 자료를 참조하시기 바랍니다.”
- “특정한 아리바스에 대한 정보를 제공하기 위해서는 더 구체적인 세부사항(예: 전체 이름, 활동 분야, 국적 등)이 필요합니다.”
- “프티오스에 관한 구체적인 정보는 제공하지 못합니다.”
- “그는 한국 항공우주 산업의 국제화와 기술 수출에도 기여했을 가능성이 있습니다.”
- “홍순엽에 대한 약력은 개인정보에 해당하는 사항이기 때문에 제공할 수 없습니다.”

다음 단계는 원소 문장 추출 생성이다. 원소 문장이란 주어진 원문장에서 개별 정보를 추출하여 생성한 문장이다. 예시는 다음과 같다.

(원문장) “1980년대 후반부터 정치활동을 시작하여, 민주노동당의 창당 멤버이자 당 대표를 역임했습니다.”

(원소 문장)

- “그는 1980년대 후반부터 정치활동을 시작했습니다.”

- “그는 민주노동당의 창당 멤버였습니다.”
- “그는 민주노동당의 당 대표를 역임했습니다.”

추출된 원소 문장은 코어 원소 사실 문장 선별의 과정을 거친다. 이 과정은 ‘사실성 검증 비대상 문장 필터링’과 유사하다. 이 과정이 별도로 필요한 이유는 문장안에 사실성 검증 대상과 비대상이 1차 필터링된 원문장에 함께 포함될 수 있기 때문이다. 예시는 아래와 같다.

(원문장) “권영길은 진보적 가치를 위해 노력해왔으며, 자세한 최신 정보나 최근 활동에 대해서는 제공된 정보가 없습니다.”

(원소 문장)

- “권영길은 진보적 가치를 위해 노력해왔습니다.”
- “권영길에 대한 자세한 최신 정보가 없습니다.”
- “권영길에 대한 최근 활동에 대해서는 제공된 정보가 없습니다.”

다음 단계에서는 각 코어 원소 문장 i 에 대해 사실성 검증을 수행한다. 한국어 위키 백과를 외부 지식 DB로 활용하였으며, 검증에 필요한 단락이 검색되어 제공된다. 검색기는 BERT 기반의 cross-encoder[3]가 적용되었다. 이렇게 검증된 개별 사실성 검증 결과를 취합하여 참(True)으로 판별된 코어 원소 문장의 비율을 백분율로 계산한다. 이 백분율 값이 FactScore [2]로 불리는 사실성 평가 점수가 된다.

3. 사실성 평가 데이터집합

사실성 평가 대상은 언어모델이 생성한 인물의 이력이다. 구체적으로 언어모델로서 GPT-4.0-Preview-0125[ChatGPT] 버전을 활용하여 인물의 이력을 생성한 문서이다. 대상 인물을 선정함에 있어서는 인기도에 따른 생성 특성을 살펴보기 위해 위키백과의 방문기록 수를 고려하였고, 인기도에 따른 충분한 양의 정보를 제공하기 위해 페이지의 텍스트 길이를 고려하였다. 한국어 문화권과 영어 문화권의 대상에 따른 생성 결과의 특성을 보기위해서 한국인 대상 인물을 54명을 선정하였고, 외국인 대상 인물은 50명 선정하였다. 표 2에 평가 대상에 대한 정보를 확인할 수 있다.

4. 사실성 평가 실험

사실성 검증 비대상 문장 필터링, 원소 문장 추출, 코어 원소 사실 문장 선별을 위해서 GPT-4.0-Preview-0125를 적용하였다. 각각의 성능은 표 1과 같다. 이 모듈들은

한국인/외국인 여부, 페이지 방문수, 텍스트 길이 등과 무관하기 때문에 해당 구분없이 전체 샘플에 대해 결과를 제시한다. 성능면에서는 각각 95%, 98%, 97%의 성능을 보여주었다. 작은 모델로의 지식 증류 등을 통한 모델 효율화 가능성을 제시해 주었다고 판단된다.

<표 1> 사실성 검증 비대상 문장 필터링, 원소 문장 추출 생성, 코어 원소 사실 문장 선별 모듈들의 성능

	검증 비대상 문장 필터링	원소 문장 추출 생성	코어 원소 사실 문장 선별
대상(건수)	974	2384	1955
정확률	95.3%	98.1%	96.8%

<표 2> 한국어 평가셋의 사실성 평가 성능

* PV: Page Views(페이지 방문수)

대상 국적	한국				
PV 백분위	90-100	90-100	60-80	40-60	20-40
최소 PV 수	30000	10000	3000	1000	500
문서 길이	5000	3000	1000	1000	700
평가 대상 건수	10	10	10	14	10
필터링 후 문서 수	8	5	7	4	7
FactScore	88.1%	56.7%	61.5%	34.0%	12.3%
사실판단 정확도	95.9%	90.0%	90.5%	97.8%	95.7%
대상 국적	외국				
PV 백분위	90-100	90-100	60-80	40-60	20-40
최소 PV 수	30000	10000	2800	1000	500
문서 길이	5000	3000	1000	1000	600
평가 대상 건수	10	10	10	10	10
필터링 후 문서 수	10	10	8	6	4
FactScore	93.0%	91.6%	90.5%	80.2%	14.1%
사실판단 정확도	97.0%	93.9%	98.5%	82.3%	95.8%

평가 대상들에 대한 사실성 평가 성능을 표 2에 제시하였다. 표에서 알 수 있는 특징은 다음과 같다. 한국인 대상 생성 문서의 경우 외국인 대상 문서에 비해 “필터링 후 문서 수”가 더 작다(6.2 : 7.6). 또한, FactScore의 경우 더 큰 차이로 작은 사실성 평가 점수를 보여준다(50.5% : 73.9%). 이 점은 생성에 사용된 언어모델이 영어 문화권에 비해 한국어 문화권에 대한 지식이 더 적게 보유하고 있음을 암시한다고 볼 수 있다. 또한, 인기도(PV: 페이지 방문수)가 낮아짐에 따라,

FactScore도 낮아지는 현상을 발견할 수 있다. 이러한 현상은 한국인 대상 문서에서 더욱 두드러지게 나타남을 확인할 수 있다.

한편, 사실판단 정확도는 시스템이 예측한 사실성 결과와 정답(ground truth)과의 일치도를 의미한다. 표에서 알 수 있듯이 결과 성능은 국적이나 인기도 등에 상관없이 거의 일정한 값을 가지고 있음을 볼 수 있다. 평균 94% 성능을 보여준다. 이 또한 작은 모델로의 효율화 가능성을 보여준다.

5 결론

본 논문에서는 한국어 생성문서의 사실성 평가를 위한 프레임워크를 제시하였다. 검증을 위한 평가셋과 평가 소프트웨어를 함께 제공하였다. 이를 통해, 최근 폭발적으로 개발되고 있는 언어모델의 텍스트 생성에 있어 사실성 능력과 사실성 평가 파이프라인 내에서의 능력을 검증할 수 있게 되었다. 또한, 거대 언어모델을 활용하여 파이프라인의 단계별 기능을 구현하였다. 실험을 통해 성능을 평가해 보았으며, 그 가능성을 확인하였다. 향후 증류 모델 개발을 통해 평가 시스템 효율화를 진행할 예정이다.

감사의 글

* 이 논문은 2024년도 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 연구임 (No. 2022-0-00369, (4세부) 전문지식 대상 판단결과의 이유/근거를 설명가능한 전문가 의사결정 지원 인공지능 기술개발)

참고문헌

- [1] Z. Guo, M. Schlichtkrull, A. Vlachos; A Survey on Automated Fact-Checking. Transactions of the Association for Computational Linguistics 2022; 10 178–206.
- [2] S. Min, K. Krishna, X. Lyu, M. Lewis, W. Yih, P. W. Koh, M. Iyyer, L. Zettlemoyer, and H. Hajishirzi, "FACTScore: Fine-grained atomic evaluation of factual precision in long form text generation," arXiv preprint arXiv:2305.14251, 2023. [Online]. Available: <https://arxiv.org/abs/2305.14251>.
- [3] 배용진, 이공주, “질의응답 시스템을 위한 지역적 대비 추정 손실 기반 한국어 단락 순위화 모델”, 한국컴퓨터종합학술대회, pp. 534-536, 2021.
- [4] OpenAI. "ChatGPT", <https://chat.openai.com/>, 2023.