

복합 추론을 위한 한국어 중심의 소형 생성 언어모델 구축

신중훈^o, 허정, 류지희, 임수종, 권오욱

한국전자통신연구원

{jhshin82, jeonghur, chrisjihee, isj, ohwoog}@etri.re.kr

Construct Small-scale, Korean-Centric Generative Language Model For Complex Reasoning

Jong-Hun Shin^o, Jeong Heo, Jihee Ryu, Soo-Jong Lim, Oh-Woog Kwon

Electronics and Telecommunications Research Institute

요약

최근 가중치에 자유롭게 접근 가능한 대형 언어모델이 공개되고, 다양한 하위태스크에서 과거와 비교하기 어려운 성능과 편의를 제공하고 있지만 여전히 실용성이 좋은 작은 생성 언어모델에 대한 연구와 공개 모델이 부족하다. 본 논문을 통해 한국어 중심의 7B 미만의 생성 언어모델 모델 3종(1.3B, 3.1B, 6.7B)을 구축하는 연구를 소개하고, 구축 중인 모델의 학습과 배포를 위한 접근 전략과 신경망 기초정보를 제공한다. 이들 중 현재 공개된 1.3B 급의 모델에 대한 문맥 내 학습 성능을 유사 규모의 공개 모델과 비교하고, 산술 연산을 수행하는 소규모의 하위 태스크를 통해서 응용 성능을 살펴본 뒤 해결해야 할 문제와 방향을 논의한다. 본 연구를 통해서 구축 중인 모델은 STEM 분야의 복합 추론을 최종 목표로 삼아 발전시키고자 한다.

주제어: 생성 언어 모델, 산술추론, 복합추론

1. 서론

생성 언어모델은 자연어 처리 분야에서 질의응답, 대화시스템을 포함해 데이터 합성 영역에서 과거와 비교할 수 없는 개선을 가져왔다. 그럼에도 불구하고, 아직 다중 추론(Multi-hop Reasoning) 및 수학 추론을 포함한 복합 추론 영역에서는 많은 도전이 필요하다. 소형 언어모델에 대한 요구는 초대형 모델의 추론 비용 감소와 맥을 같이할 것이나, 응용 시스템의 차별화나 영업비밀이나 개인정보와 같은 민감 정보 처리가 필요한 경우 등 그 수요는 여전히 존재할 것으로 여겨진다.

최근에는 Blllossom [1], KULLM [2]와 같이 가중치에 자유롭게 접근 가능한 LLaMA 3 [3], Mistral 모델 [4]에 기반, 한국어 어휘 사전 영역을 기존 사전에 더하는 사전 확장 기법을 적용하고 대용량의 한국어 말뭉치를 사용해 다양한 한국어 대상 태스크를 다룰 수 있는 고성능 모델이 공개되고 있다. 하지만 이들 모델은 그 근본이 되는 기초 모델의 크기가 8B 이상으로 커짐에 따라, 파라미터 효율적 미세조정 기법의 접근성이 우수함에도 불구하고 여전히 학습과 추론에 많은 시간과 비용을 요구한다. 또한, 이들은 지도 미세조정(Supervised Fine-Tuning; SFT) 및 선호도 정렬(Preference Alignment) 과정을 통해 추가학습된 모델로, 정렬되지 않은 기초 모델에 비해 추가 미세조정에서 약간의 성능 상 페널티를 감수해야 한다. SOLAR [5]와 같이 기초 모델이 공개된 경우에도, 한국어를 위한 어휘 임베딩 영역이 존재하지 않아 추가 작업이 요구된다. 이러한 이유로, 우리는 복합 추론을 위한 연구를 수행하기 위해 STEM 분야를 위한 7B 미만의 모델을 from scratch로 학습하고, 이들을 개선해나

가고자 한다.

한편, 생성 언어모델의 파라미터 수는 창발적 능력(Emergent Abilities)의 출현 [6] 뿐만 아니라 지식 도메인 다양성에 막대한 영향을 미치기 때문에, 본 연구에서 다루고자하는 7B 이하의 모델들은 앞서 언급된 공개 모델의 역할과 달리 범용 질의응답 및 지시 이행 용도에서 뚜렷한 한계를 지니고 있다고 봐도 무방하다. 이러한 바탕을 감안해, 본 연구에서는 수십B 이상의 대형 언어모델에서 기대하는 범용 추론능력을 단순히 작은 모델에서 유사하게 재현하는 것을 목표로하는 대신, 제한된 도메인 내에서 복잡한 추론을 수행할 수 있는 모델로 이어지기 위한 기초 모델을 만드는데 집중하고자 한다. 좀 더 세부적으로는, 7B 미만의 작은 모델에서 복합추론을 수행할 수 있는 한국어 중심의 생성 언어모델 구축을 다룬다. 본 연구를 통해 구축된 모델은 Huggingface Hub¹를 통해 자유롭게 액세스 가능하며, 추후 1.3b 이외 규모(3.1B, 6.7B 등)에 대한 공개도 계획되어 있다.

앞서 서술한 바와 같이 최종적으로는 STEM 분야의 복합 추론을 목표로 두고 있으나, 본 논문은 해당 연구의 기반을 구축하는 과정에서 그 목표가 되는 소형 생성언어 모델의 구축 과정을 정리한다. 2장에서는 제한된 자원을 가진 조직에서 생성 언어모델 학습을 위한 접근 전략과 데이터, 토큰나이저, 데이터, 하이퍼파라미터 등 구축 중인 언어모델의 기초 정보를 소개한다. 3장에서는 구축된 기초 모델의 진단을 위해 문맥 내 학습(In-Context Learning; 이하 ICL로 표기) 성능을 살펴보

¹HF Hub URL: <https://huggingface.co/etri-lirs,1.3B> 모델: <https://huggingface.co/etri-lirs/egpt-1.3b-preview>

며, 추가적으로 상대적 요구 지식의 폭이 적은 수학 분야, 그 중에서도 산술 연산을 중심으로 해당 모델의 응용 가능성을 확인한다. 4장에서는 본 연구를 위해 참조된 관련 연구와, 본 연구에서의 한계와 논의가 필요한 부분을 다루며, 5장에서 향후 연구 방향을 살펴본다.

2. 복합 추론을 위한 생성 언어모델 구축

2.1 생성 언어모델 구축을 위한 학습 데이터 및 학습 전략 상세

본 연구에서 활용하고 있는 사전학습 목적의 학습 데이터는 다양한 경로를 통해 공개된 비영리 목적 활용 데이터와 함께, 자체적으로 수집, 합성한 데이터를 혼합하여 사용한다. AIHUB에서 공개된 대화/MRC/요약/번역/RAW 데이터 등의 텍스트 데이터, KISTI 논문 전문 데이터셋 [7], 국립국어원의 모두의 말뭉치 [8], 한국어 위키피디아 데이터셋(2020년 덤프) [9], KcBERT 데이터셋 [10] 등을 포함한 한국어 데이터셋과 함께, 공개된 영미권 데이터셋인 SlimPajama-627B [11], 그리고 STEM 분야를 위해 Proof-pile-2 데이터셋 [12], autoMath-Text [13] 등 약 800B급 토큰으로 구성된 데이터를 샘플링하여 사용한다. 각 모델마다 학습에 사용된 데이터의 크기와 비율이 다르게 구성되는데, 1.3B 모델에서는 토큰 수 기준으로 한국어의 비중이 1/3 정도를 차지하는 250B 토큰 규모의 데이터, 3B 이상 모델에서는 한국어의 비중이 1/5로 구성되어있는 550B 토큰 규모의 데이터를 사용한다. 여기에 수학 분야를 위해 산술 연산 데이터를 합성 [14]하여 사전학습에 활용한다. 이 때 각 숫자 토큰의 통계적 분포가 비슷하게 유지되도록 구성하는 것이 핵심이며, 약 9B 토큰 규모로 이루어져있다.

사전학습 단계에서는 사용할 데이터를 조기에 확보하고, 이들의 비중을 사전에 조정하여 학습 대상 데이터셋을 고정 후 학습을 진행, 목표 학습 토큰 수에 도달할 때 마다 이들을 평가하고 모델을 릴리즈하는 것이 일반적이다. 이러한 생명주기를 갖는 모델은 사전학습에 소요되는 기간이 짧을 수록 최신 지식을 보유하고, 외부 연구 기관에서 릴리즈하는 다른 경쟁 모델과 그 흐름을 같이할 수 있게될 가능성이 높아진다. 또한 그 배경에는 신경망의 가소성(plasticity) 문제 [15], 데이터의 학습 간 추가/변경에 의한 데이터의 통계 왜곡, I.I.D 가설 위배 등 많은 연구가 필요한 학습 성능 저하문제가 깔려 있어, 통념상 데이터셋의 구성을 바꾸어가며 지속적으로 학습하는 접근 방법이 좋은 결과를 보일 수 없다는 것이 작용하고 있다. 하지만, 해당 관련 연구에 뛰어들어 그 흐름을 같이 하기 위해서는 천문학적 비용이 요구되고 있는 실정이고, 다행히 앞서 언급한 배경이 생성 언어모델의 지속적 학습에 어떤 영향과 결과를 초래하는지에 대해서도 뚜렷하게 밝혀지지 않은 상태 [16]이다. 이에 따라, 우리는 보유하고 있는 인적, 물적 자원의 한계를 인

정하고 이러한 생명 주기 대신 SW 개발과 유사하게 가중치를 점진적으로 변화시켜나가는 지속적 배포(Continuous Release) 전략을 사용한다. 또한, 향후 지속적 가중치 변화를 통해 발생할 수 있는 성능 저하 문제를 마주하고, 이들을 극복할 수 있는 연구를 시도할 수 있는 기회로 삼고자 한다.

2.2 사전학습 모델의 상세

본 연구를 위해, 서버워드 토큰라이저 모델을 별도로 구성하였다. 구성간 핵심은 두 가지로, 첫째, 숫자 토큰이 서버워드로 묶이는 것을 방지하기 위해 아라비아 숫자 영역을 모두 사전토큰화(Pre-tokenize)하였다. 여러 숫자가 하나의 토큰으로 묶이는 것으로, 숫자 토큰의 통계적 특성 왜곡이 산술 연산 단계의 실수를 크게 증가시킬 것으로 판단했기 때문이다. 둘째, 한국어가 가급적 개념 단위로 처리될 수 있도록 형태소를 고려한 서버워드 토큰화 전략 [17]을 사용하였다. 서버워드 토큰화 모델을 위해, 미등록어가 개념적으로 존재하지 않도록 Byte-level BPE를 sentencepiece를 사용하여 학습하였다. 사전학습 말뭉치의 10%를 샘플링, 서버워드 어휘 토큰 32,000개와 함께 최소 바이트 단위 영역과 예약 토큰 영역으로 1천개 미만의 어휘 토큰으로 구성하였다.

모델의 아키텍처는 1.3B 모델과 6.7B 모델에 GPT-NeoX [18] 호환² 아키텍처를 사용하였으며, 3.1B 모델은 LLaMA 아키텍처를 사용한다. 두 모델의 차이는 MLP 레이어에 SiLU 활성화 함수를 결합한 Gated Linear Unit(SwiGLU)를 적용하고, Layer Norm에 RMSNorm을 사용했다는 점에서 구조적 차이를 가진다. 이러한 이형적 아키텍처 선정은 연구 초기 단계에서 1.3B와 6.7B 모델 구축을 목표로 진행하다가, 이후에 3B급 규모의 모델의 구축을 추가 목표로 설정했기 때문이다. 초기 단계 당시에는 연구를 위한 장비들이 BFloat16을 지원하지 않는 경우가 많아 FP16 정밀도와 함께 LLaMA 1 아키텍처를 사용하는 것으로 결정하였으나, FP16 정밀도에서 학습 불안정성이 관측되어 최종적으로 GPT-NeoX 아키텍처를 사용하게 되었다. 이후 연구 장비가 Ampere 이후 세대로 대체되는 비중이 증가하고, Bfloat16 정밀도를 사용한 추론 환경이 개선됨에 따라 이후에 기획한 3.1B 급의 모델은 BFloat16 정밀도와 함께 LLaMA 아키텍처를 사용하게 되었다. 상세 하이퍼파라미터 구성에도 차이가 있는데, 3B 모델의 경우는 연구 초기 단계 이후에 등장한 사전학습 연구들을 검토하고, 300M 급의 소규모 파일럿 모델을 통해 레이어와 임베딩 차원, 그리고 MLP 구성을 위한 Intermediate Size 비율을 달리하여 비교 실험을 수행, LM perplexity, 속도, 확장성 등을 고려하여 하이퍼파라미터 구성을 조정하였다. 상세한 신경망 구성은 표1에

²6.7B 모델에서 학습 안정성 개선을 위해 MHA에서 attention bias를 제거하였기 때문에, 초기 GPT-NeoX 모델과 차이가 있음.

표 1. 모델 신경망 하이퍼파라미터 구성

파라미터 수	1.3B	3.1B	6.7B
어휘사전 크기	32,384	32,768	32,768
레이어 수	24	16	32
Hidden Dim.	2048	2560	4096
Intermediate Size	8192	20,480	16,384
Attention Heads	16	32	32
RoPE Emb. Base	10k	10k	500k

정리하였다.

1.3B 모델의 경우에는, 2,048 토큰 길이로 구성된 샘플을 약 500B tokens 사전학습하였고, 이후 LLaMA2 모델의 장기 문맥 확장 연구 [19]를 참고하여 RoPE base를 500k로 증가시키고, 같은 학습 데이터를 샘플 당 16,384 토큰 길이로 구성해 약 134B tokens를 추가 학습 하는 방법으로 긴 문맥을 처리할 수 있게 확장하였다. (하기 1.3b-longctx 버전) 후속 공개 예정인 3B와 6.7B 모델은 24년 9월 현재 각각 약 400B tokens, 371B tokens 가량 학습이 진행 중에 있다. 본 연구에서 언급되는 모든 모델의 학습에는 A100 80GB 8장으로 구성된 단일 호스트를 주로 사용하고 있으며, 필요에 따라 호스트 당 두 개의 100GbE(RoCE) 인터커넥트로 연결된 최대 3대의 호스트를 활용하여 학습하고 있다. 본 논문에서는 1차적으로 구축이 완료, 공개된 1B급 모델을 중심으로 성능을 평가하고자 한다.

3. 실험, 평가

3.1 기초모델의 문맥 내 학습 성능 평가

사전학습 후 정렬 과정을 거치지 않은 기초모델의 평가를 위해, KOBEST [20] 벤치마크 데이터셋을 사용한 0/5/10-shot 문맥 내 학습(In-Context Learning; 이하 ICL로 표기)을 사용하였다. 벤치마크 데이터셋의 도메인이 목표 도메인에 부합하지 않기 때문에, 절대적 성능 수치와 함께 예시의 수에 따라 점증적으로 성능이 향상되는지를 함께 살펴보았다. 평가를 위해 EleutherAI/lm-evaluation-harness [21] 버전 0.4.3를 사용하였으며, 동급 규모의 모델 비교군 3종으로 polyglot-ko-1.3b([22], 23년 6월 공개), tinyllama-v1.1([23], 24년 1월 공개), gemma-2-2b([24], 24년 7월 공개. 2.5B 파라미터 규모)등 연구 초기 단계의 모델과 최신 모델을 사용해 본 연구의 구축 결과물이 갖는 경쟁력을 확인하였다.

상기 표2에서 비교군 모델은 전체 모델 명을 기입하였고, 본 연구에서 구축, 공개된 버전을 current로, 그리고 장기 문맥 대응을 위해 추가학습된 모델을 1.3b-longctx로 명기하였다. 본 연구를 통해 구축한 모델이 성능 수치와 샘플-성능 상승

표 2. 2B 이하 기초모델의 문맥 내 학습 능력 평가

Shots	0-shot	5-shots	10-shots
Models	Avg. F1	Avg. F1	Avg. F1
tinyllama-v1.1	0.3659	0.4631	0.4615
polyglot-ko-1.3b	0.4592	0.5305	0.5061
gemma-2-2b	0.4298	0.4608	0.4642
1.3b-current	0.4506	0.5141	0.5238
1.3b-longctx	0.4697	0.5561	0.5775



2991와 7416의 곱을 구하시오.

문제를 수식으로 바꾸면 $2991 * 7416$ 이 됩니다.

이를 전개하면, 아래와 같습니다:

$$\begin{aligned} 2991 * 7416 &= 7416 * (2000 + 900 + 90 + 1) = 7416 * \\ &2000 + 7416 * 900 + 7416 * 90 + 7416 * 1 = 14832000 + \\ &6674400 + 667440 + 7416 = 21506400 + 667440 + 7416 \\ &= 22173840 + 7416 = 22181256 \end{aligned}$$

따라서 정답은 22181256 입니다.

그림 1. 한국어 중심의 산술 문제 풀이 데이터셋 예시

능력을 더 잘 유지하고 있음을 확인할 수 있으며, 그 중 장기 문맥을 지원하는 모델에서 상대적으로 더 좋은 샘플-성능 관계를 가지는 것을 확인할 수 있다. 비교군에 속하는 한국어 중심 생성 모델인 polyglot-ko 모델은 그 연구에서 밝힌 바와 같이 본 연구에서 사용되는 데이터 대비 더 많은 데이터(약 ~860GB)를 사용했음에도 불구하고, 학습량은 계산 효율성을 위해 213B tokens만을 학습했다고 알려져 있다. 이로 인해, 예제 샘플의 수가 증가되었을 때 문맥 내 학습의 효과가 충분히 발현되지 않은 것으로 추정된다. 또 다른 비교군인 tinyllama의 경우 LLaMA 2와 동일하게 영어 어휘가 주축이 되는 32k 크기의 Byte-level BPE 토큰나이를 사용하는 관계로, 입력 토큰이 과분할(over-fragmentation)되어, 늘어난 샘플 수가 오히려 성능을 악화시켰을 것으로 판단된다. 상대 비교군 중 24만 단어로 구성된 어휘사전과 상대적으로 더 긴 문맥(8천 토큰 시퀀스)으로 학습, 위의 약점을 보완한 기초모델인 gemma-2-2b 모델은 ICL 성능이 비교적 잘 유지되는 것을 알 수 있다.

3.2 산술 연산 및 추론 능력 평가

산술 능력 평가를 위해 Math401 데이터셋 [25]을 사용하여 정확도를 평가하였다. 해당 데이터셋은 테스트 데이터로만 구성되어 있기 때문에, 미세조정 목적의 한국어 산술 데이터셋을 별도로 구축, 활용하였다. Huggingface Hub의 abeiler/Num_Rep_Arithmetic 데이터셋의 수식과 풀이를 가져와 파싱 후, 그림1과 같이 한국어 산술 문제와 CoT-like 응답

표 3. 미세조정 모델 및 사전정렬된 모델의 Math401 데이터셋을 통한 산술 능력 평가 결과

미세조정 모델	정답 수	오답 수	정확도(Acc.)
polyglot-ko-1.3b	68	331	16.95%
	(62)	(211)	(22.54%)
tinyllama-v1.1	117	283	29.17%
	(107)	(167)	(38.90%)
gemma-2-2b	127	273	31.67%
	(117)	(158)	(42.54%)
1.3b-current	190	209	47.38%
	(184)	(89)	(66.90%)
1.3b-longctx	140	260	34.91%
	(125)	(149)	(45.45%)
정렬 된 모델	정답 수	오답 수	정확도(Acc.)
tinyllama-v1.1-chat	45	355	11.22%
	(41)	(233)	(14.90%)
gemma-2b-it	180	220	44.88%
	(147)	(127)	(53.45%)
gemma-2-2b-it	251	149	62.59%
	(208)	(65)	(75.63%)

텍스트 데이터를 생성하였다. 구축된 10만 개의 샘플 중 중 8천 개를 샘플링 후 이를 학습/검증 셋트로 나누어 미세조정을 실시하였다. 평가에 사용된 각 기초모델은 동일한 방법으로 전체 미세조정하였다. 학습률은 $8e-5$ (1.3b-longctx는 $4e-5$), 배치 크기는 16, 2 epoch 학습하였으며, 학습률 스케줄러로 Cosine Decaying(Warmup=0)을 사용했다. 학습 정밀도의 경우에는, 모델이 지원하는 형식(tinyllama는 Bfloat16, gemma-2-2b의 경우 float32 등)을 그대로 사용했다. 평가 데이터는 원시 데이터의 수식을 그대로 보존한 상태에서, 같은 지시문을 사용하도록 템플릿을 구성하였다. 또한, 가장 마지막 숫자 토큰을 정규표현식으로 분리하여 소숫점 4자리 수로 반올림 후 양쪽을 맞추어 정답을 비교하였다. 추론은 vllm 엔진 [26]을 사용하고, 샘플링 파라미터는 temperature 0.0, top-p 1.0으로 설정하였다. 미세조정에 사용한 학습데이터는 정수와 유리수의 사칙 연산만을 다루고 있기 때문에, Math401 데이터셋의 앞 274개 (275개 분리 후, 가장 앞의 오일러 방정식 제외)를 분리하여 사칙연산 데이터셋만을 골라 추가로 정확도를 살펴보았다. 표3에서 각 모델 별 점수가 전체 데이터셋, 그리고 사칙연산 평가 부만 분리한 것을 괄호로 묶어 제시하였다.

소량의 데이터를 사용한 미세조정 실험 및 평가를 통해서 사전학습 된 모델의 전이학습 능력을 평가하였으나, 초기/최대

학습률, epoch 수와 같이 각 기초 모델에 맞는 하이퍼파라미터 구성이 제각기 다를 것임은 자명하다. 또한, 지시 이행을 위한 미세조정 절차와 지시 이행 데이터셋의 구조와 샘플링에 따라서도 이들 결과가 크게 달라질 수 있기 때문에, 정렬까지 완료하여 배포된 모델을 사용하여 동등 평가셋에 대해 각 모델이 발현할 수 있는 산술 연산 성능을 별도로 확인하였다. 사전정렬된 모델은 각 모델이 사용하는 기본 템플릿 포맷에 질문에 답을 하라는 영어 지시문과 수식을 입력으로 구성하여 가급적 온전한 성능을 낼 수 있게 하였다. 성능 평가를 확인하였을 때, polyglot-ko와 tinyllama, gemma-2 사이의 간극을 통해 숫자 토큰을 사전이 분리했느냐 아니냐의 차이가 주는 영향력을 간접적으로 확인할 수 있으며, 본 모델의 경쟁력과 함께 사전학습 단계에서 산술 연산과 관련된 숫자 토큰의 노출 정도에 따른 성능 차이를 확인할 수 있다. 실험 결과 중 모델의 일부 하이퍼파라미터 수정 후 추가 사전학습을 수행한 1.3b-longctx 모델에서 성능 저하가 관측되었는데, 이에 대해서는 추가 학습 간 숫자 합성 데이터가 학습에 많이 참여하지 못해 발생한 것으로 추정된다. 이를 해소하기 위해 추가 사전학습 간 배치 크기를 늘리고 학습률을 낮추고, Weight Decay Rate를 0에 가깝게 만드는 등 하이퍼파라미터 조정이 포함된 Cooldown Stage [23]의 도입이 필요할 것으로 본다. 한편, 표3의 아랫부에 위치한 정렬 모델의 성능 평가 결과를 함께 가늠했을 때, 사전학습 이후 정렬에 사용된 데이터와 기법에 따른 개선의 여지가 많이 남아있는 것 역시 확인할 수 있으며, 불과 4개월 가량의 출시 기간 차이를 갖는 구글의 gemma 1/gemma 2 모델의 성능 차이에서 소형 모델의 발전에 도전하는 연구의 치열함도 엿볼 수 있다.

상기 산술능력 평가 결과의 정성적 평가를 추가로 실시했을 때, 소형 생성 언어모델이 어려움을 겪는 산술 연산 영역은 다음과 같았다:

- $\pm 10^{10}$ 이상, 큰 수에 대한 사칙 연산식
- 괄호에 의한 우선순위 처리를 요하는 연산식
- (소수점이 포함된 수들의) 제곱 연산 및 나누기
- 로그 및 삼각함수의 연산

이러한 취약 연산 영역의 특징은 Chain-of-Thought 스타일의 긴 풀이가 적고, 사전학습 단계에서 쉽게 노출되지 않는 토큰 시퀀스에 해당한다는 것으로 정리할 수 있다. 언어모델의 학습 메커니즘을 감안하면 이들 연산에 필요한 CoT 스타일의 정답을 어떻게 구축하느냐에 따라 향후 개선 가능성을 크게 좌우할 수 있을 것으로 예상된다.

4. 관련연구 및 논의

본 연구에서 사용하고 있는 사전학습 모델 전략과 관련하여, 대형 사전학습 언어모델의 지속 학습 문제를 연관지을 수 있다.

사전학습 언어모델의 지속학습은 신규 도메인 적응을 위해 이루어지는 경우가 많은데, Task drifting이 일어나는 많은 지속 학습 연구에서 다른 문제와 다른 점이 존재한다. 지속학습이 단순히 기존 지식의 망각 형태로 이어지는 것이 아니라, 기존 학습된 지식과 신규 지식 사이의 의미적 연관성에 따라 다른 양상을 보인다는 연구 [16]가 있다. 한편, 생성 언어 모델의 장기 지속 학습을 위해 학습 컨디션을 복원하기 위한 연구 [27]와 같이 적절한 replay 데이터의 샘플링과 Weight Decaying, 학습률 스케줄러의 변화를 통한 접근 방법과, Continual Backprop 연구 [28]와 같이 기여도가 작은 가중치를 초기화하는 방법을 적용하는 것을 고려할 필요가 있다.

한편, 본 연구에서는 기초 모델의 성능 평가 방법으로 polyglot-ko 모델 [22]과 같이 Few-shot ICL을 사용하였다. 대안적 평가 방안으로 T0-Eval [29]과 같이, 사전학습된 모델에 고정된 집합의 프롬프트 튜닝 데이터셋을 사용해 학습 후 Unseen task의 일반화 성능을 평가하는 방법을 생각해 볼 수 있다. 하지만, 현재의 생성 모델 평가에서는 지시 이행 능력 평가, Multi-choice 선택 등 대부분의 성능 평가용 데이터셋은 정렬이 완료된 모델에 대한 지식 인출 능력 평가에 집중되어 있는데, 이들은 파라미터 크기와 선형적 비례관계에 놓여있기에, 제한적 도메인과 태스크를 목표로 두는 소형 모델의 성능을 평가하기에는 다소 미흡한 점이 있다. 개선을 위해, Copying task와 같이 주어진 입력에서 일반화 된 처리를 기대하는 태스크와 Few-shot ICL을 결합한 ICLEval [30]과 같은 시도를 고려할 수 있다.

그 밖에도, 작은 모델에 대한 수학 추론 응용과 관련해서는 평가에 사용되는 데이터셋(예: GSM8k)을 기반으로 Program-of-Thought 스타일의 합성 데이터 생성과, 검증자 도구를 결합하는 시도로 성능 개선을 보인 tinygsm [31] 등 작은 모델에서 추론 성능 개선을 위한 다양한 접근 방법을 검토 할 수 있다. 이러한 시도는 프로그램 코드에서 사용될 변수명 등이 주어진 입력과 같은 캐릭터 클래스를 가지지 못하는 한국어-코드 생성 사이의 참조 불일치로 인해 생성 일관성이 크게 나빠질 것으로 예상되는 문제가 있고, 이를 개선하는 시도를 고려할 필요가 있다.

5. 결론

지금까지 현재 진행중인 소형 생성 언어모델의 구축에 관련된 상세한 내용을 살펴보고, 약간의 실험을 통해 공개된 모델의 기초 성능을 문맥 내 학습 평가를 통해 확인해보았다. 또한, 소량의 한국어 중심 산술 연산 데이터를 통해 모델을 튜닝하고, 산술 연산 수식의 예측 성능을 확인하였다. 같은 조건의 미세조정 데이터를 사용하여 경쟁력이 있음을 확인하였으나, 정렬 후 배포된 공개 모델의 성능은 더욱 좋아, 고품질의 지시 이행을

위한 정렬 데이터와 학습 과정을 적용하여 개선해야 할 여지가 많음도 확인할 수 있었다. 향후에는 아직 공개되지 못한 기초 모델의 학습, 성능 개선을 통해 연구 활동에 활용할 수 있는 추가 모델을 공개하고, 복합 추론을 위한 지시 이행 능력 향상 연구를 지속할 예정이다.

감사의 글

이 논문은 2024년도 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 연구임 (RS-2023-00216011, 사람처럼 개념적으로 이해/추론이 가능한 복합인공지능 원천기술 연구)

참고문헌

- [1] C. Choi *et al.*, “Optimizing language augmentation for multilingual large language models: A case study on korean,” *arXiv preprint:2403.10882*, 2024. [Online]. Available: <https://arxiv.org/abs/2403.10882>
- [2] S. Lee *et al.*, “Kullm: Learning to construct korean instruction-following large language models,” *Annual Conference on Human and Language Technology*, pp. 196–202, 2023.
- [3] A. Dubey *et al.*, “The llama 3 herd of models,” 2024. [Online]. Available: <https://arxiv.org/abs/2407.21783>
- [4] A. Q. Jiang *et al.*, “Mistral 7b,” 2023. [Online]. Available: <https://arxiv.org/abs/2310.06825>
- [5] S. Kim *et al.*, “SOLAR 10.7B: Scaling large language models with simple yet effective depth up-scaling,” *Proceedings of the 2024 Conf. of the NAACL: Human Language Technologies (Volume 6: Industry Track)*, Y. Yang, A. Davani, A. Sil, and A. Kumar, Eds., pp. 23–35, Jun. 2024. [Online]. Available: <https://aclanthology.org/2024.naacl-industry.3>
- [6] J. Wei *et al.*, “Emergent abilities of large language models,” 2022. [Online]. Available: <https://arxiv.org/abs/2206.07682>
- [7] 한국과학기술정보연구원, “국내 논문 전문 텍스트 데이터셋. version 1.0.” 2021. [Online]. Available: <https://doi.org/10.23057/38>
- [8] 국립국어원, “모두의 말뭉치,” 2023. [Online]. Available: <https://kli.korean.go.kr/corpus/>
- [9] ko nlp, “Korpora: Korean corpora archives,” 2020. [Online]. Available: <https://ko-nlp.github.io/Korpora/>

- [10] J. Lee, “Kcbert: Korean comments bert,” *Proceedings of the 32nd Annual Conference on Human and Cognitive Language Technology*, pp. 437–440, 2020.
- [11] D. Soboleva *et al.*, “Slimpajama: A 627b token cleaned and deduplicated version of redpajama,” June 2023. [Online]. Available: <https://huggingface.co/datasets/cerebras/SlimPajama-627B>
- [12] Z. Azerbayev *et al.*, “Llemma: An open language model for mathematics,” 2024. [Online]. Available: <https://arxiv.org/abs/2310.10631>
- [13] Y. Zhang, Y. Luo, Y. Yuan, and A. C.-C. Yao, “Automathtext: Autonomous data selection with language models for mathematical texts,” *arXiv preprint arXiv:2402.07625*, 2024.
- [14] Z. Yang *et al.*, “Gpt can solve mathematical problems without a calculator,” *arXiv preprint:2309.03241*, 2023. [Online]. Available: <https://arxiv.org/abs/2309.03241>
- [15] C. Lyle *et al.*, “Understanding plasticity in neural networks,” 2023. [Online]. Available: <https://arxiv.org/abs/2303.01486>
- [16] Çağatay Yıldız *et al.*, “Investigating continual pretraining in large language models: Insights and implications,” 2024. [Online]. Available: <https://arxiv.org/abs/2402.17400>
- [17] K. Park, J. Lee, S. Jang, and D. Jung, “An empirical study of tokenization strategies for various Korean NLP tasks,” *Proceedings of the 1st Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics and the 10th International Joint Conference on Natural Language Processing*, K.-F. Wong, K. Knight, and H. Wu, Eds., pp. 133–142, Dec. 2020. [Online]. Available: <https://aclanthology.org/2020.aacl-main.17>
- [18] S. Black *et al.*, “GPT-NeoX-20B: An open-source autoregressive language model,” *Proceedings of BigScience Episode #5 – Workshop on Challenges & Perspectives in Creating Large Language Models*, A. Fan, S. Ilic, T. Wolf, and M. Gallé, Eds., pp. 95–136, May 2022. [Online]. Available: <https://aclanthology.org/2022.bigscience-1.9>
- [19] W. Xiong *et al.*, “Effective long-context scaling of foundation models,” 2023. [Online]. Available: <https://arxiv.org/abs/2309.16039>
- [20] D. Kim, M. Jang, D. S. Kwon, and E. Davis, “Kobest: Korean balanced evaluation of significant tasks,” 2022. [Online]. Available: <https://arxiv.org/abs/2204.04541>
- [21] L. Gao *et al.*, “A framework for few-shot language model evaluation,” 07 2024. [Online]. Available: <https://zenodo.org/records/12608602>
- [22] H. Ko *et al.*, “A technical report for polyglot-ko: Open-source large-scale korean language models,” 2023. [Online]. Available: <https://arxiv.org/abs/2306.02254>
- [23] P. Zhang, G. Zeng, T. Wang, and W. Lu, “Tinyllama: An open-source small language model,” 2024. [Online]. Available: <https://arxiv.org/abs/2401.02385>
- [24] G. Team *et al.*, “Gemma 2: Improving open language models at a practical size,” 2024. [Online]. Available: <https://arxiv.org/abs/2408.00118>
- [25] Z. Yuan *et al.*, “How well do large language models perform in arithmetic tasks?” 2023. [Online]. Available: <https://arxiv.org/abs/2304.02015>
- [26] W. Kwon *et al.*, “Efficient memory management for large language model serving with pagedattention,” 2023. [Online]. Available: <https://arxiv.org/abs/2309.06180>
- [27] K. Gupta *et al.*, “Continual pre-training of large language models: How to (re)warm your model?” 2023. [Online]. Available: <https://arxiv.org/abs/2308.04014>
- [28] S. Dohare, R. S. Sutton, and A. R. Mahmood, “Continual backprop: Stochastic gradient descent with persistent randomness,” 2022. [Online]. Available: <https://arxiv.org/abs/2108.06325>
- [29] V. Sanh *et al.*, “Multitask prompted training enables zero-shot task generalization,” *International Conference on Learning Representations*, 2022. [Online]. Available: <https://openreview.net/forum?id=9Vrb9D0WI4>
- [30] W. Chen *et al.*, “Iclevl: Evaluating in-context learning ability of large language models,” 2024. [Online]. Available: <https://arxiv.org/abs/2406.14955>
- [31] B. Liu *et al.*, “Tinygsm: achieving >80% on gsm8k with small language models,” 2023. [Online]. Available: <https://arxiv.org/abs/2312.09241>